Classificação de Dados SAR/PolSAR usando TabR e TabNet

Marcelo R. Rios e **Jodavid Ferreira**

Departamento de Estatística — Universidade Federal de Pernambuco



26º SINAPE — Gramado (RS) — Setembro de 2026

Estrutura da Apresentação

1. **Motivação e Objetivo**
2. **Dados SAR/PolSAR**
3. **Modelo: Random Forest**
4. **Modelo: TabNet**
    - Atenção sequencial
    - Feature Transformer
5. **Modelo: TabR**
    - Retrieval-augmented
6. **Dados Experimentais**
    - São Francisco (AIRSAR)
    - Foulum (EMISAR)
7. **Resultados**
    - Métricas de avaliação
    - Mapas de classificação
8. **Conclusões**
9. **Referências**

Motivação

- Sensoriamento remoto por radar de abertura sintética (**SAR/PolSAR**) gera dados com características complexas:
  - Altas dimensionalidades
  - Presença do ruído **speckle**
  - Dados tabulares derivados de matrizes de covariância
- Modelos clássicos como **Random Forest** são utilizados como métodos de classificação de dados em sensoriamento remoto
- Recentemente, arquiteturas de **Deep Learning** voltadas para dados tabulares surgiram:
  - **TabNet** (Arik & Pfister, 2021) — Atenção sequencial
  - **TabR** (Gorishniy et al., 2023) — Retrieval-augmented

Objetivo: Comparar o desempenho de Random Forest, TabNet e TabR na classificação de dados SAR/PolSAR

O que é SAR?

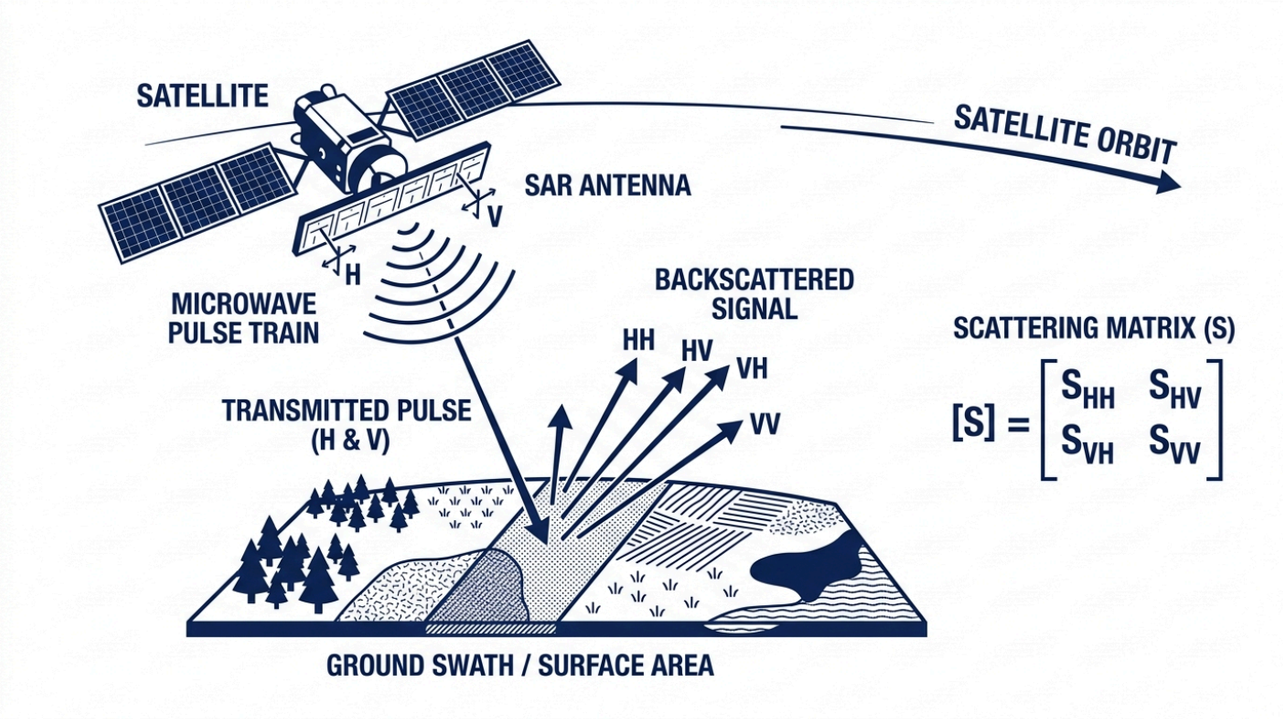


Ilustração esquemática do imageamento SAR com polarizações e a matriz de espalhamento.

- **SAR** (*Synthetic Aperture Radar*): sensor ativo que emite pulsos de micro-ondas e mede o sinal retroespalhado
- Funciona **dia e noite**, independente de condições climáticas

Dados PolSAR Multi-look

Os retornos PolSAR multi-look são representados por uma **matriz hermitiana** definida positiva 3×3:

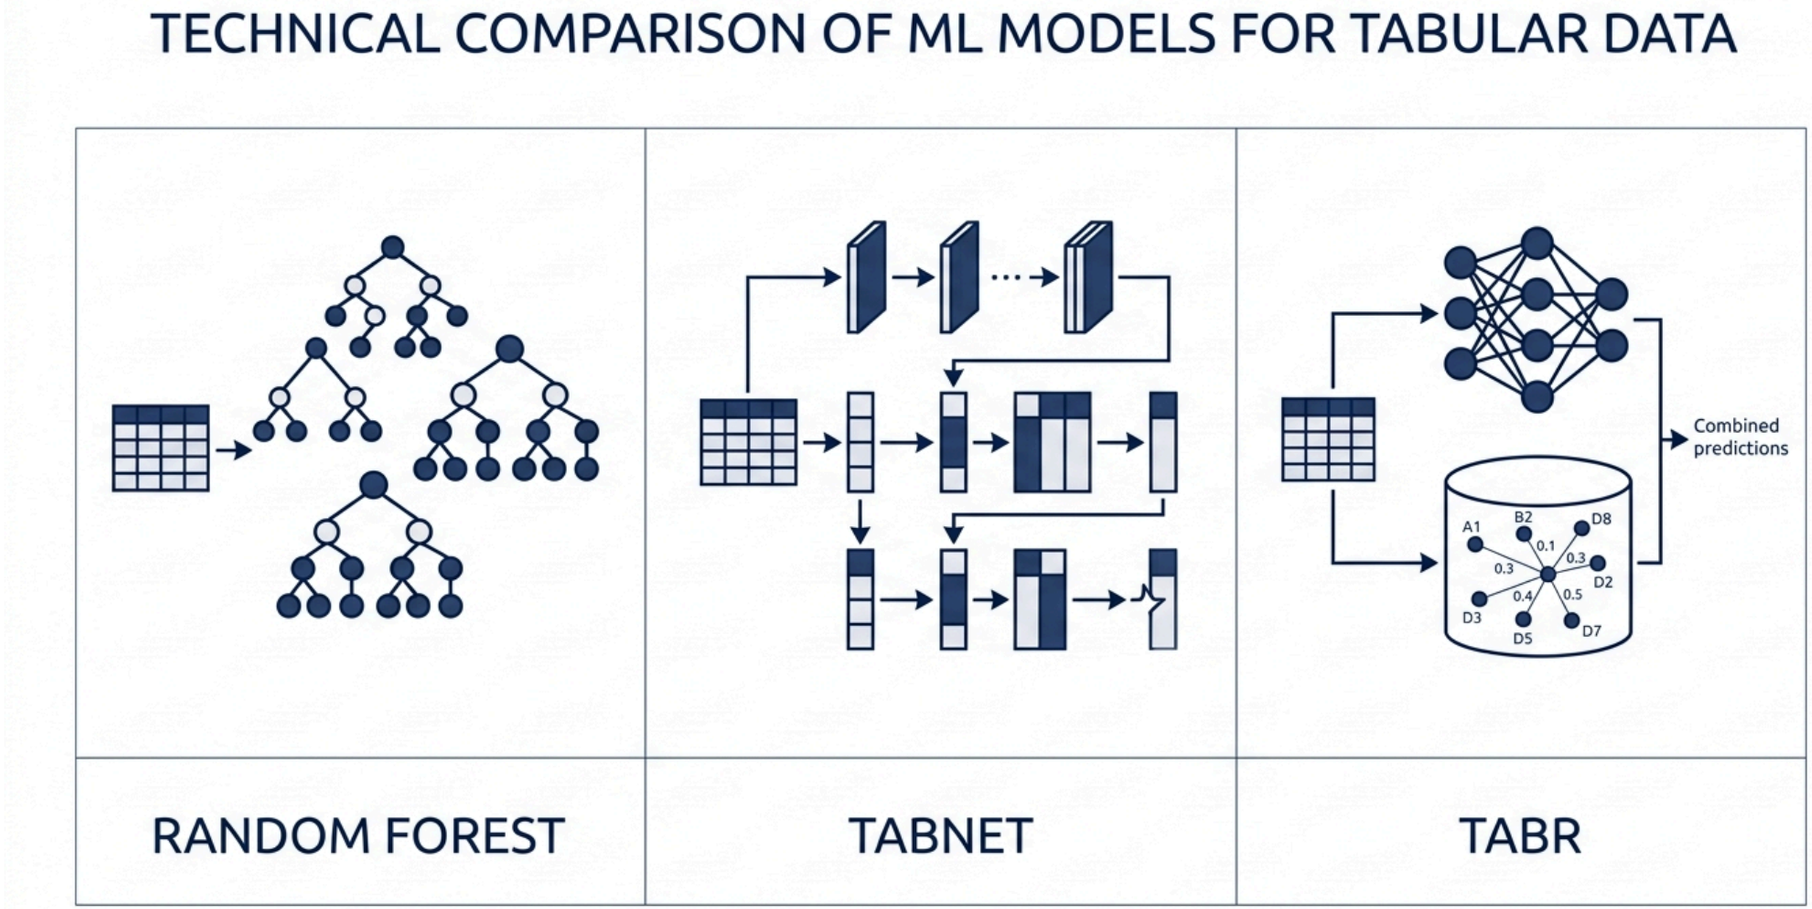
$$\mathbf{Z} = \begin{bmatrix} |Z_{HH}|^2 & Z_{HH-HV} & Z_{HH-VV} \\ Z_{HH-HV}^* & |Z_{HV}|^2 & Z_{HV-VV} \\ Z_{HH-VV}^* & Z_{HV-VV}^* & |Z_{VV}|^2 \end{bmatrix}$$

onde os **produtos internos** entre canais de polarização são:

$$Z_{A-B} = \langle Z_A, Z_B \rangle = Z_A Z_B^*, \quad A, B \in \{HH, HV, VV\}$$

Variáveis utilizadas: Vetor de intensidades $\mathbf{I}(i) = [I_1(i), I_2(i), I_3(i)]^\top \in \mathbb{R}_+^3$ correspondente aos canais HH, HV e VV no pixel i.

Métodos - RF, TabNet e TabR



Random Forest

O **Random Forest** (Breiman, 2001) é um método de *ensemble* baseado em árvores de decisão:

1. **Bagging**: B subconjuntos bootstrap do treino
2. **Árvores de decisão**: em cada nó, seleciona-se aleatoriamente m variáveis ($m \ll p$)
3. **Agregação**: classificação por **votação majoritária**

$$\hat{y}(\mathbf{x}) = \text{mode}\{h_b(\mathbf{x})\}_{b=1}^{B}$$

onde:

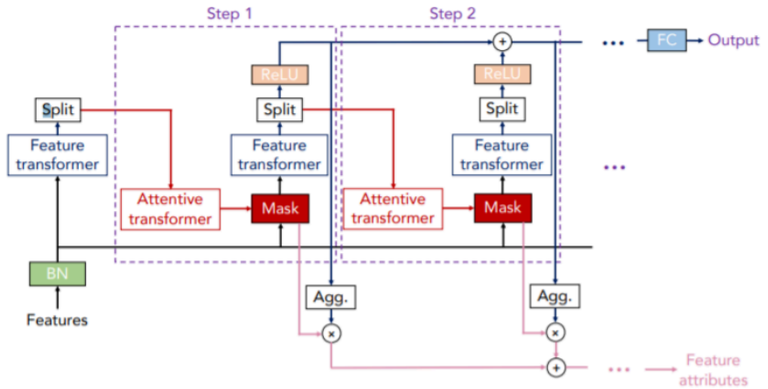
- $\mathbf{x} \in \mathbb{R}^p$ é o vetor de covariáveis (variáveis preditoras) de uma nova observação — no contexto PolSAR, $\mathbf{x} = [I_1, I_2, I_3]^\top$ representa as intensidades dos canais HH, HV e VV
- p é o número total de variáveis preditoras disponíveis
- B é o número de árvores de decisão no ensemble
- $h_b(\mathbf{x})$ é a classe predita pela b-ésima árvore para a observação $\mathbf{x}$, com $b = 1, \ldots, B$
- $m \ll p$ é o número de variáveis sorteadas aleatoriamente em cada nó de divisão da árvore (tipicamente $m = \lfloor \sqrt{p} \rfloor$ para classificação)
- $\text{mode}\{\cdot\}$ denota a moda do conjunto, ou seja, a classe votada pela maioria das B árvores

Vantagens:

- Robusto a *overfitting*
- Lida com variáveis heterogêneas
- Não requer normalização
- É utilizada em aplicações de sensoriamento remoto (Belgiu & Drăguţ, 2016)

TabNet — Arquitetura Geral

Attentive Interpretable Tabular Learning



Arquitetura do codificador (*encoder*) do TabNet com passos de decisão sequenciais. Fonte: Arik & Pfister (2021).

- **Mecanismo de atenção sequencial**: seleciona variáveis relevantes a cada passo $j = 1, \ldots, N_{\text{steps}}$, onde N_{steps} é o número total de passos de decisão
- **BN** (*Batch Normalization*): normaliza $\mathbf{f} \in \mathbb{R}^p$ — o vetor de p features de entrada — antes do processamento; $\mathbf{f}$ representa as covariáveis brutas do pixel a ser classificado
- **Interpretabilidade**: fornece importância de variáveis via máscaras de atenção $\mathbf{M}[j] \in \mathbb{R}^p$, onde cada componente indica o peso atribuído à j-ésima feature no passo atual

TabNet — Atenção Sequencial

A máscara de atenção no passo j é:

$$\mathbf{M}[j] = \text{sparsemax}\left(\mathbf{P}[j-1] \cdot h_j(\mathbf{a}[j-1])\right)$$

onde:

- $\mathbf{M}[j] \in \mathbb{R}^p$ é a **máscara de atenção** no passo j: vetor de pesos que indica quais das p variáveis de entrada são selecionadas naquele passo
- $\text{sparsemax}(\cdot)$ é uma função de normalização esparsa — similar ao softmax, mas que produz vetores com muitos zeros, forçando esparsidade na seleção de variáveis
- $\mathbf{P}[j-1] \in \mathbb{R}^p$ é o **prior scale** do passo anterior, que penaliza variáveis já muito utilizadas nos passos anteriores:

$$\mathbf{P}[j] = \prod_{k=1}^{j} (\gamma - \mathbf{M}[k])$$

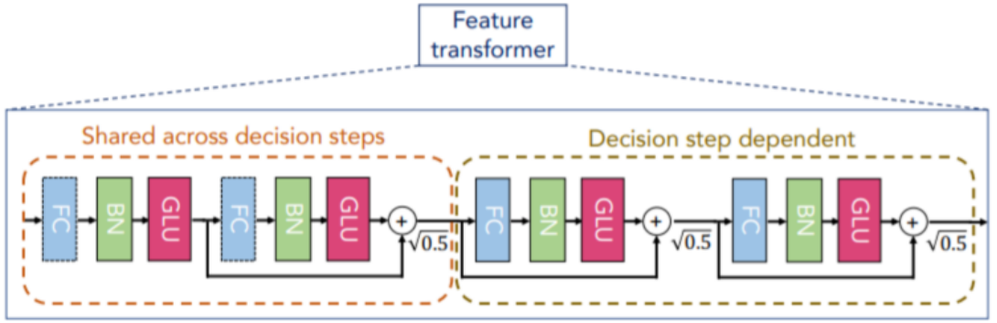
com $\mathbf{P}[0] = \mathbf{1}_p$ (vetor de uns, sem penalização no início), e k indexando os passos já percorridos

TabNet — Atenção Sequencial

- $\gamma \in [1, +\infty)$ é o coeficiente de **relaxamento**: quando $\gamma = 1$ cada variável só pode ser usada uma vez; valores maiores permitem reuso
- $h_j(\cdot)$ é uma rede neural FC (*Fully Connected*) + BN (*Batch Normalization*) específica do passo j, que mapeia o estado $\mathbf{a}[j-1]$ para logits de atenção
- $\mathbf{a}[j-1] \in \mathbb{R}^{N_a}$ é o **estado processado** no passo anterior, produzido pelo *Feature Transformer*; N_a é a dimensão da representação interna



Attentive Transformer



Feature Transformer

TabNet — Feature Transformer

O **Feature Transformer** processa os dados selecionados em cada passo de decisão:

- Combina dois blocos:
  1. **Compartilhado** entre todos os passos
  2. **Dependente** de cada passo

Cada bloco consiste em:

$$\text{FC} \rightarrow \text{BN} \rightarrow \text{GLU}$$

onde **GLU** (*Gated Linear Unit*) é:

$$\text{GLU}(\mathbf{x}) = \sigma(\mathbf{W}_1\mathbf{x} + \mathbf{b}_1) \odot (\mathbf{W}_2\mathbf{x} + \mathbf{b}_2)$$

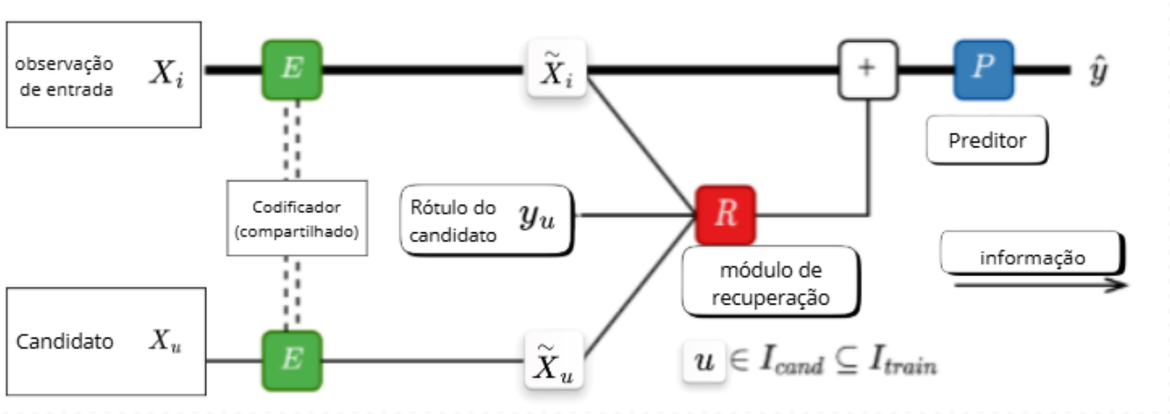
TabNet — Feature Transformer

- $\mathbf{x} \in \mathbb{R}^{N_a}$ é o vetor de representações internas da camada anterior (saída da BN), com N_a sendo a dimensão do espaço de representação
- $\mathbf{W}_1, \mathbf{W}_2 \in \mathbb{R}^{N_a \times N_a}$ são **matrizes de pesos** aprendíveis: $\mathbf{W}_1$ controla a "porta" (gate) e $\mathbf{W}_2$ controla o conteúdo a ser filtrado
- $\mathbf{b}_1, \mathbf{b}_2 \in \mathbb{R}^{N_a}$ são os vetores de **viés** (*bias*) associados a cada transformação linear
- $\sigma(\cdot)$ é a **função sigmoide** $\sigma(z) = (1 + e^{-z})^{-1}$, que comprime os valores para o intervalo $(0, 1)$, funcionando como uma **porta de controle** sobre o fluxo de informação
- $\odot$ denota o **produto de Hadamard** (element-wise): multiplica elemento a elemento os dois vetores, efetivamente escalando cada dimensão de $(\mathbf{W}_2\mathbf{x} + \mathbf{b}_2)$ pelo gate $\sigma(\mathbf{W}_1\mathbf{x} + \mathbf{b}_1) \in (0, 1)^{N_a}$

A saída do passo j é dividida: parte vai para a **decisão** e parte para as **informações de atenção** do passo seguinte.

TabR — Arquitetura Geral

Tabular Deep Learning Meets Nearest Neighbors



Arquitetura do TabR: codificador compartilhado, módulo de recuperação e preditor. Fonte: Gorishniy et al. (2023).

O TabR pertence à classe de **retrieval-augmented deep learning models**, combinando:

- **Componente paramétrico**: rede neural composta por um **codificador** $E : \mathbb{R}^p \to \mathbb{R}^d$ (que projeta as p covariáveis para um espaço latente de dimensão d) e um **preditor** $P : \mathbb{R}^d \to \mathcal{Y}$ (que mapeia a representação enriquecida para o espaço de classes $\mathcal{Y}$)
- **Componente não-paramétrico**: módulo de **recuperação** (*retrieval*) que, dado o vetor latente $\tilde{\mathbf{x}}_i = E(\mathbf{x}_i)$ da observação de consulta i, busca os k vizinhos mais similares em I_{train} (índice do conjunto de treino) e agrega suas informações de rótulo como contexto

TabR — Formalização Matemática

Dada uma observação $\mathbf{x}_i \in \mathbb{R}^p$ (vetor de p covariáveis do pixel i a classificar), o TabR opera em três etapas:

1. Codificação (Encoder E):

$$\tilde{\mathbf{x}}_i = E(\mathbf{x}_i) \in \mathbb{R}^d$$

onde $E(\cdot)$ é a rede neural codificadora (MLP) com parâmetros aprendíveis, e d é a dimensão do espaço latente de representação ($d \ll p$ em geral)

2. Recuperação (Retrieval R):

Para cada candidato $u \in I_{\text{cand}} \subseteq I_{\text{train}}$ — onde I_{train} é o conjunto de índices de todas as observações de treino e I_{cand} é um subconjunto candidato (pode ser todo I_{train}) — calcula-se a similaridade do cosseno entre as representações latentes:

$$s(i, u) = \frac{\tilde{\mathbf{x}}_i^\top \tilde{\mathbf{x}}_u}{\|\tilde{\mathbf{x}}_i\| \cdot \|\tilde{\mathbf{x}}_u\|}$$

onde $\tilde{\mathbf{x}}_i^\top \tilde{\mathbf{x}}_u$ é o produto interno entre os vetores latentes e $\|\cdot\|$ denota a norma Euclidiana. O valor $s(i, u) \in [-1, 1]$ mede o ângulo entre os vetores: quanto mais próximo de 1, mais similares as observações i e u.

TabR — Formalização Matemática

A informação de contexto recuperada, agregando os k vizinhos mais similares ($\text{Top-}k$), é:

$$\mathbf{c}_i = \sum_{u \in \text{Top-}k} \alpha_u \cdot \phi(y_u)$$

onde $\alpha_u \propto \exp(s(i,u)/\tau)$ são pesos de atenção softmax (com temperatura $\tau > 0$) normalizados sobre os k vizinhos; $y_u \in \mathcal{Y}$ é o rótulo de classe do vizinho u no treino; e $\phi : \mathcal{Y} \to \mathbb{R}^d$ é uma função de embedding que projeta o rótulo para o espaço latente

3. Predição (P):

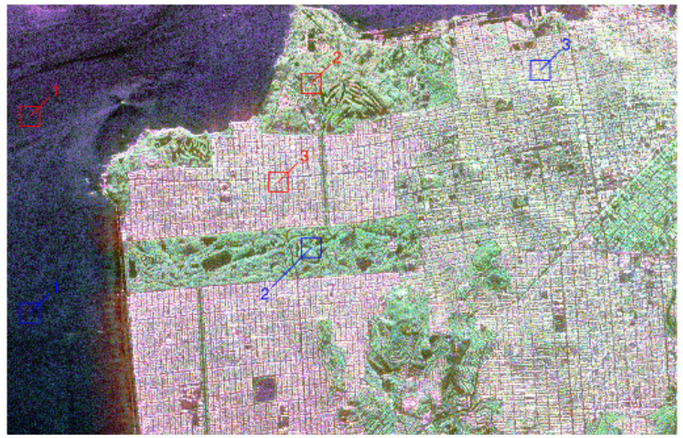
$$\hat{y}_i = P\left(\tilde{\mathbf{x}}_i + \mathbf{c}_i\right)$$

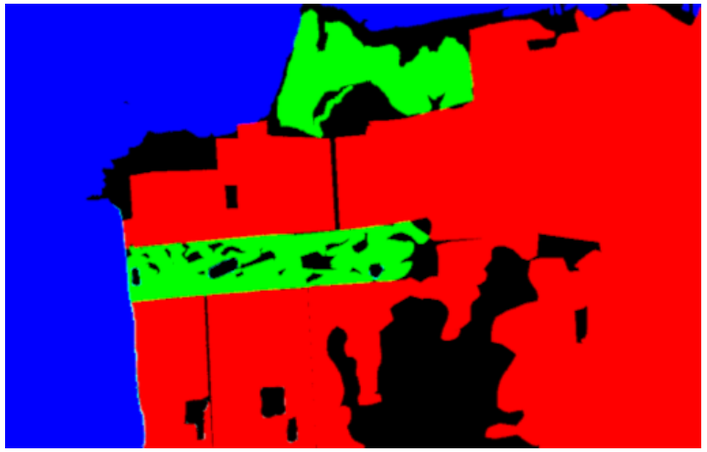
onde $\hat{y}_i \in \mathcal{Y}$ é a classe predita; $P(\cdot)$ é a rede preditora (MLP) que recebe a representação enriquecida pelo contexto $\left(\tilde{\mathbf{x}}_i + \mathbf{c}_i\right) \in \mathbb{R}^d$, combinando informação paramétrica (encoder) e não-paramétrica (vizinhos recuperados)

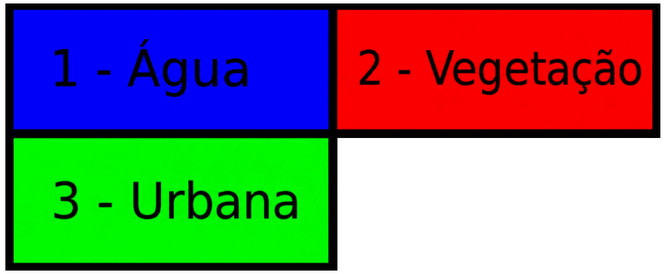
Resultados

Dados Experimentais

Região de São Francisco (AIRSAR)







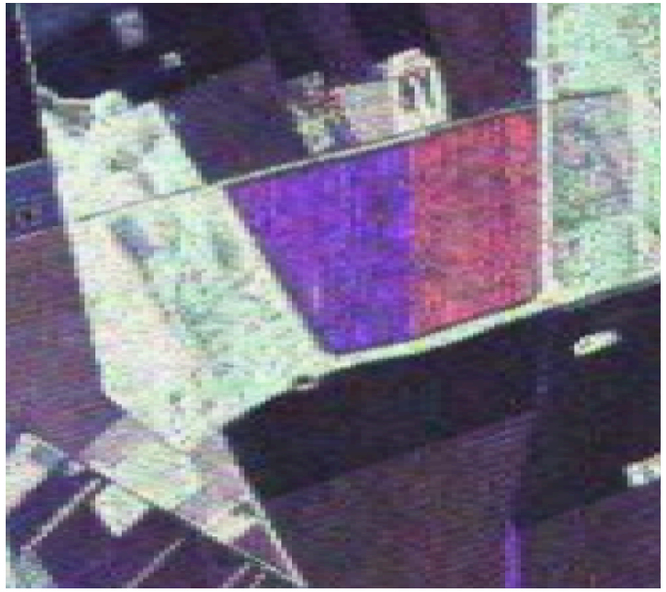
- Adquirida pelo radar **AIRSAR** (NASA/JPL)
- **3 classes**: Água, Vegetação, Área Urbana

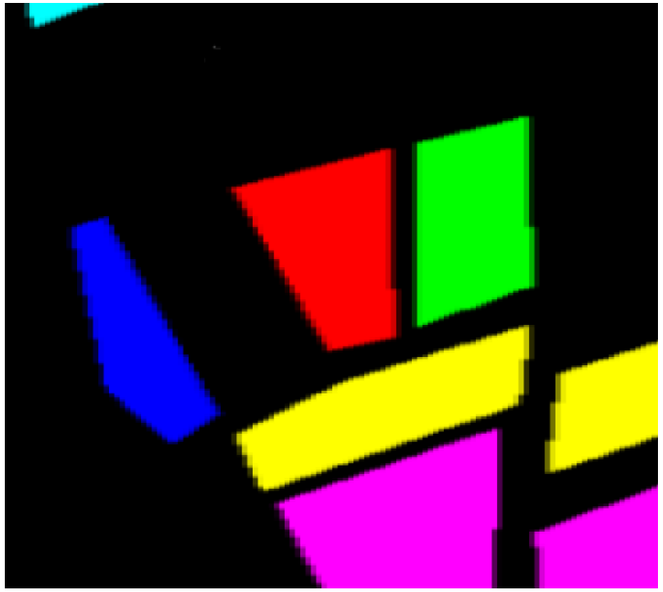
- Amostras de treino e teste: janelamento 31×31
  - **961 observações** por área
  - 2 áreas por classe (treino + teste)

- Variáveis: intensidades $|Z_{HH}|^2$, $|Z_{HV}|^2$, $|Z_{VV}|^2$

Dados Experimentais

Região de Foulum (EMISAR)





1 - Trigo	2 - Colza
3 - Centeio	4 - Conífera
5 - Aveia	6 - Background

- Sensor **EMISAR** (Dinamarca)
- **5 classes** de plantações
- 2 áreas por classe (treino + teste)
- Tamanhos variáveis: **961 a 1.861 pixels** por área

Resultados

Métricas de Avaliação

Os modelos foram avaliados com 2 métricas, adequadas ao contexto multiclasse:

	Predito A	Predito B	Predito C
Real A	n_{11}	n_{12}	n_{13}
Real B	n_{21}	n_{22}	n_{23}
Real C	n_{31}	n_{32}	n_{33}

Métrica	Fórmula
Acurácia	$\text{Acc} = \frac{\sum_{i=1}^{k} n_{ii}}{N}$
Kappa	$\kappa = \frac{p_o - p_e}{1 - p_e}$

em que n_{ii} é o número de amostras corretamente classificadas na classe i, e N é o total de amostras, k é o número de classes, p_o é a proporção de acertos observada (equivalente à acurácia) e p_e é a concordância esperada ao acaso, calculada a partir da distribuição marginal das classes na matriz de confusão:

$$p_e = \sum_{i=1}^{k} \frac{(n_{i+} \times n_{+i})}{N^2}$$

em que n_{i+} é é a linha i e n_{+i} é a coluna j.

Resultados

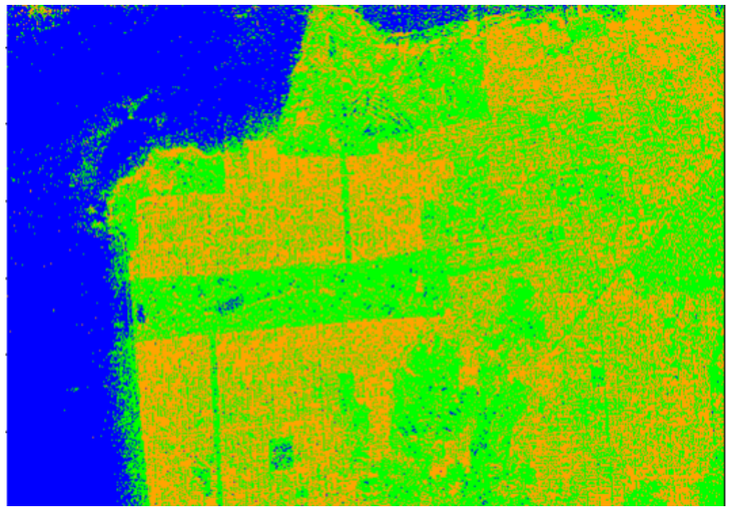
Resultados — São Francisco

Modelo	Acurácia	Kappa
Random Forest	0,8318	0,7477
TabNet	0,8471	0,7706
TabR	**0,8588**	**0,7882**

Destaque: O TabR obteve o melhor desempenho global em São Francisco, com acurácia de **85,88%** e Kappa de **0,7882**.

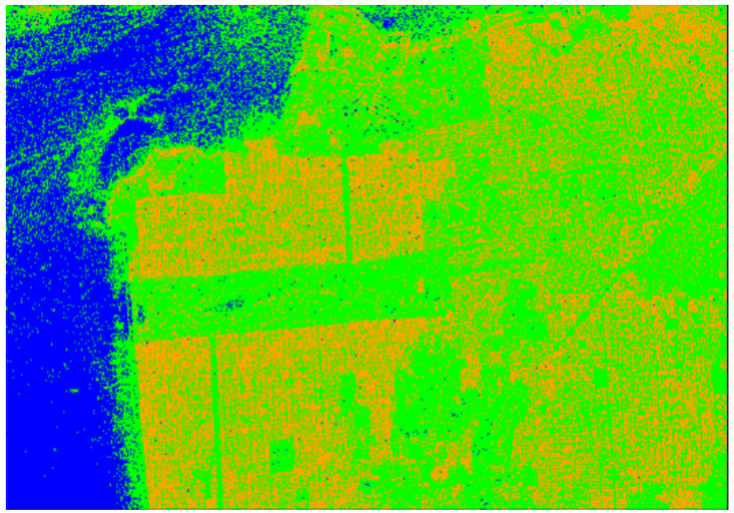
Resultados

Mapas — São Francisco



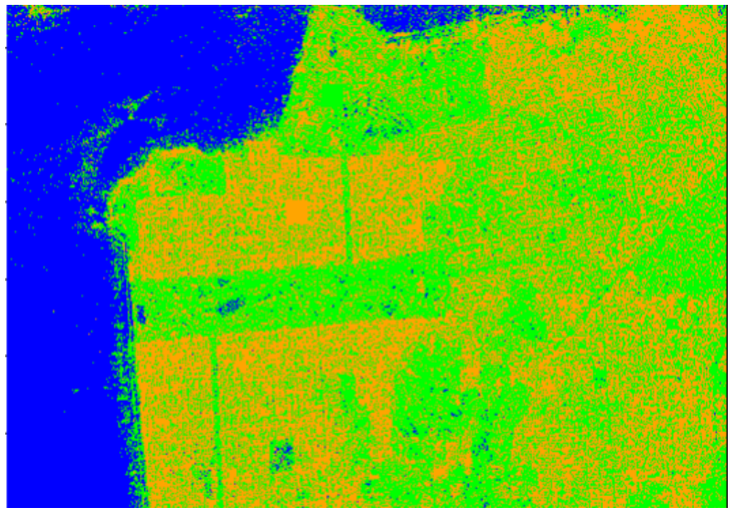
(b) TabR

Melhor separação entre classes



(c) TabNet

Suavização levemente maior



(d) Random Forest

Maior fragmentação nas bordas

🔵 Água 🟢 Vegetação 🟠 Área Urbana

Resultados

Resultados — Foulum

Modelo	Acurácia	Kappa
TabR	0,8649	0,8355
Random Forest	0,8712	0,8423
TabNet	**0,8760**	**0,8489**

Destaque: Para Foulum, o TabNet apresentou o melhor desempenho global, com acurácia de **87,60%** e Kappa de **0,8489**.

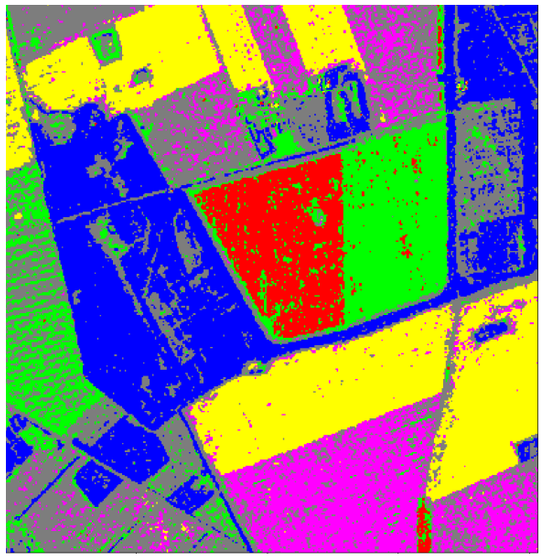
Resultados

Mapas — Foulum



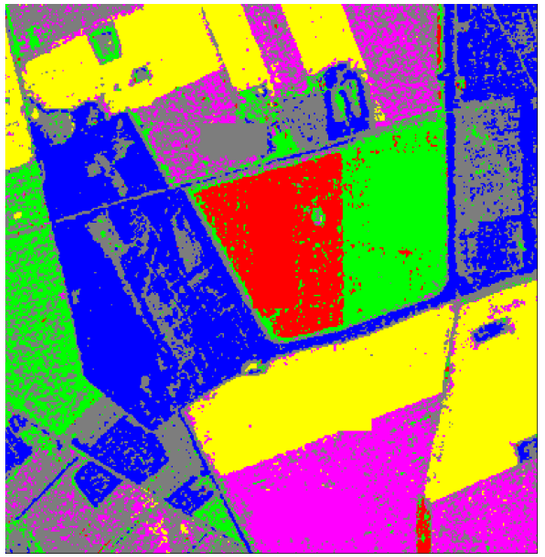
(b) TabR

Boa definição de fronteiras



(c) TabNet

Melhor desempenho global



(d) Random Forest

Maior presença de ruído

🔴 Trigo 🟢 Colza 🟣 Centeio 🔵 Conífera 🟡 Aveia ⚫ Background

Resultados

Análise Comparativa

São Francisco (3 classes)

Modelo	Acc	Kappa
RF	0,832	0,748
TabNet	0,847	0,771
TabR	**0,859**	**0,788**

Foulum (6 classes)

Modelo	Acc	Kappa
TabR	0,865	0,836
RF	0,871	0,842
TabNet	**0,876**	**0,849**

- **TabR** se destacou com fronteiras mais claras
- Random Forest apresentou maior erro de classificação
- **TabNet** melhor em cenários com mais classes
- TabR e RF com desempenho similar

Observação: A superioridade varia com a complexidade da cena — o que sugere que a escolha do modelo deve ser orientada pela aplicação.

Conclusões

1. O **TabR** demonstrou melhor desempenho na classificação da imagem de São Francisco (**3 classes**), com superioridade nas métricas de acurácia e Kappa.

2. O **TabNet** apresentou melhor desempenho na região de Foulum (**6 classes**), indicando capacidade de lidar com cenários mais complexos.

3. O **Random Forest** permanece competitivo, especialmente em cenários com maior variabilidade intra-classe.

4. Modelos de **Deep Learning para dados tabulares** (TabNet e TabR) são alternativas promissoras para classificação de dados SAR/PolSAR.

Referências

- Arik, S. O. and T. Pfister (2021). **TabNet: Attentive Interpretable Tabular Learning.** *Proceedings of the AAAI Conference on Artificial Intelligence.*
- Belgiu, M. and L. Drăguţ (2016). **Random forest in remote sensing: A review.** *ISPRS J. Photogrammetry and Remote Sensing*, 114, 24–31.
- Breiman, L. (2001). **Random Forests.** *Machine Learning*, 45(1), 5–32.
- Ferreira, J. A., H. Coêlho, and A. D. Nascimento (2021). **A family of divergence-based classifiers for PolSAR imagery.** *Int. J. Remote Sensing*, 42(4), 1201–1229.
- Gorishniy, Y., I. Rubachev, et al. (2023). **TabR: Tabular deep learning meets nearest neighbors.** *arXiv preprint arXiv:2307.14338.*
- Goodfellow, I., Y. Bengio, and A. Courville (2016). **Deep Learning.** MIT Press.
- Lee, J.-S. and E. Pottier (2017). **Polarimetric Radar Imaging.** CRC Press.
- Moreira, A. et al. (2013). **A tutorial on synthetic aperture radar.** *IEEE GRSM*, 1(1), 6–43.
- Mountrakis, G., J. Im, and C. Ogole (2011). **SVMs in remote sensing: A review.** *ISPRS J.*, 66(3), 247–259.

OBRIGADO!

Jodavid Ferreira

https://jodavid.github.io | jodavid.ferreira@ufpe.br



UNIVERSIDADE
FEDERAL
DE PERNAMBUCO

Slide produzido com quarto

